

Previsão de Churn

Modelagem e Avaliação (ML)

Agenda

- 01 **Introdução**
 - 02 **Dataset**
 - 03 **Prevenção de Data Leakage**
 - 04 **Os três modelos selecionados**
 - 05 **Métricas de Avaliação e Resultados**
 - 06 **Conclusão**
-

Introdução

- O objetivo é classificar se um cliente irá cancelar o serviço na empresa de telecomunicações (Churn = Yes) ou permanecer ativo (Churn = No).
- Classificação binária supervisionada: o modelo aprende padrões históricos dos clientes e usa esse conhecimento para prever o comportamento futuro de novos registros.
- Variável-alvo: coluna Churn (Yes = 26,6% | No = 73,4%)
- Um modelo que simplesmente chuta 'nenhum cliente vai cancelar' acerta 73% das vezes. A acurácia isolada não é uma métrica confiável neste contexto.

Dataset

Kaggle — Telco Customer Churn

- Dataset público da Telco — 7.043 clientes, 21 variáveis
- Grupo de variáveis divididos em: perfil do cliente, serviços contratados, dados financeiros e de contrato.
- Tratamentos realizados na EDA:
 1. Coluna customerID removida (identificador único, sem valor preditivo).
 2. Coluna TotalCharges convertida de string para numérico (11 linhas com valor vazio removidas).
 3. Coluna Churn convertida de Yes/No para 1/0 para compatibilidade com os algoritmos.

Estratégia de divisão

- O conjunto de teste deve simular dados futuros e desconhecidos, qualquer contaminação torna o modelo artificialmente perfeito.
- O dataset foi dividido em 80% treino / 20% teste antes de qualquer transformação.
- A divisão utiliza `random_state=42` para garantir reprodutibilidade e `stratify=y` para manter a proporção de ~26% de Churn em ambos os blocos, evitando amostras acidentalmente desequilibradas.

Prevenção de data leakage

3 regras anti-leakage adotadas no projeto

- O StandardScaler calcula média e desvio padrão exclusivamente com os dados de treino.
- O balanceamento sintético de classes é aplicado unicamente no bloco de treino, após a divisão. O teste permanece com a distribuição real (~26% / ~74%), simulando o cenário real de produção.
- Os 11 registros com TotalCharges vazio foram excluídos antes da divisão, não preenchidos por média global, evitando que uma estatística calculada sobre o dataset completo influencie o treino.

Os três modelos selecionados

Regressão Logística

- Modelo de classificação binária supervisionada
- Calcula a probabilidade de churn utilizando função sigmoide
- Alta velocidade e simplicidade
- Fácil interpretação dos coeficientes
- Permite identificar fatores associados ao cancelamento
- Utilizada como referência inicial de desempenho (baseline) para comparação com outros modelos.

Os três modelos selecionados

Árvore de Decisão

- Captura relações não-lineares entre variáveis
- Cria regras intuitivas do tipo "Se $\rightarrow$ Então"
- Fácil interpretação dos resultados
- Identifica padrões complexos de churn
- Auxilia a tomada de decisão das áreas de negócio
- Introduz maior capacidade preditiva em relação ao modelo baseline

Os três modelos selecionados

Random Forest

- Conjunto de 100 Árvores de Decisão
- Decisão final baseada em votação majoritária
- Reduz overfitting e melhora a generalização
- Mais robusto para dados reais
- Melhor equilíbrio entre precisão e recall
- Modelo escolhido para buscar o maior desempenho preditivo

Métricas de avaliação


- Falso Negativo: previu "fica" mas o cliente saiu → perde o cliente sem chance de reter
Falso Positivo: previu "sai" mas ele ficaria → custo de desconto desnecessário
- Recall: mede quantos clientes que cancelaram foram identificados corretamente e reduz a ocorrência de falsos negativos
- Precisão: mede quantos clientes classificados como Churn realmente cancelaram e evita desperdício de recursos de retenção
- F1-Score: equilíbrio entre Precisão e Recall
- Acurácia: percentual total de acertos e utilizada apenas como métrica complementar

Resultados

	Acurácia	Precisão	Recall (Sensibilidade)	F1-Score
Regressão Logística	0.7441	0.5132	0.7273	0.6018
Árvore de Decisão	0.7043	0.4666	0.7834	0.5848
Random Forest	0.7491	0.5187	0.7781	0.6225

Random Forest = maior Precisão sem abrir mão do Recall

Resultados



Conclusão

Random Forest: Modelo Recomendado

- Recall de aproximadamente 78%
- Identifica a maioria dos clientes com risco de cancelamento
- Melhor equilíbrio entre Precisão e Recall
- Reduz perdas por evasão de clientes
- Mais eficiente na alocação de recursos de retenção

Conclusão

Fluxo de Utilização

1. Base de clientes é enviada ao modelo
2. Modelo calcula a probabilidade de Churn
3. Clientes com maior risco são priorizados
4. Equipe de Customer Success realiza ações de retenção
5. Novos resultados alimentam futuras análises

Conclusão

Limitações e possíveis melhorias

- O modelo apresentou resultados satisfatórios, mas ainda existem oportunidades claras para aumentar sua precisão e valor de negócio.
- Dataset contém apenas dados cadastrais e financeiros, inclusão de dados de uso pode aumentar a assertividade.
- Criação de novas variáveis derivadas (ex: relação entre cobranças mensais e totais) tem potencial para melhorar a capacidade preditiva sem novos dados.

Obrigada pela atenção!

natasha.sales@aluno.ifsp.edu.br
